

Software Effort Estimation – Machine Learning Modeling Report

****Dataset:**** Maxwell Software Effort Estimation Dataset

****Prepared for:**** Rodolfo

****Prepared by:**** Savio Mendes

1. Executive Summary

Este relatório apresenta a etapa de ****Modelagem de Machine Learning**** do projeto **Agile Estimator**, cujo objetivo é desenvolver um modelo capaz de estimar o esforço de desenvolvimento de software com base em características técnicas, organizacionais e de complexidade dos projetos.

Nesta fase, foram treinados e avaliados diferentes modelos de regressão utilizando o dataset previamente preparado no ****Marco 1 – Engenharia de Dados****.

O processo incluiu validação cruzada robusta, ajuste de hiperparâmetros, comparação de desempenho entre modelos e rastreamento completo dos experimentos utilizando MLflow.

Ao final, foi possível identificar o modelo com melhor desempenho para o problema proposto, além de gerar artefatos prontos para utilização em etapas futuras do projeto.

2. Objetivo da Modelagem

O objetivo principal desta etapa foi prever a variável:

****`effort\_hours`****

Essa variável representa o esforço total necessário para o desenvolvimento de projetos de software, medido em horas.

O problema foi tratado como um ****problema de regressão supervisionada****, onde o modelo aprende a partir de dados históricos para realizar previsões futuras.

3. Dataset Utilizado

Foi utilizado o dataset previamente tratado no Marco 1, contendo aproximadamente **62** observações reais de projetos de software.

As variáveis utilizadas no modelo incluem:

- * Métrica de tamanho:

- * ``function_points``

- * Componentes principais (PCA):

- * ``PC1``

- * ``PC2``

A escolha dessas variáveis foi baseada na redução de dimensionalidade e na eliminação de multicolinearidade realizada na etapa anterior.

4. Metodologia

4.1 Divisão dos Dados

O dataset foi dividido em:

- * **80% treino**

- * **20% teste (holdout final)**

Essa divisão permite avaliar o desempenho real do modelo em dados não vistos durante o treinamento.

4.2 Validação Cruzada

Devido ao tamanho reduzido do dataset, foi utilizada uma estratégia robusta de validação:

- * **Repeated K-Fold Cross Validation**

- * 5 folds

- * 10 repetições

Essa abordagem reduz variância nas métricas e melhora a confiabilidade da avaliação dos modelos.

4.3 Modelos Avaliados

Foram testados diferentes algoritmos de regressão clássicos:

- * Regressão Linear Regularizada (Ridge e Lasso)
- * Random Forest Regressor
- * Gradient Boosting Regressor
- * Support Vector Regressor (SVR)

Cada modelo foi encapsulado em um **Pipeline**, garantindo consistência no processo de treinamento.

4.4 Otimização de Hiperparâmetros

Foi utilizado **GridSearchCV** para encontrar a melhor configuração de cada modelo.

Os parâmetros ajustados incluíram:

- * Regularização (Ridge/Lasso)
- * Profundidade e estrutura de árvores (Random Forest)
- * Taxa de aprendizado e número de estimadores (Gradient Boosting)
- * Parâmetros do kernel (SVR)

4.5 Métricas de Avaliação

Os modelos foram avaliados utilizando:

- * **MAE (Mean Absolute Error)**
- * **RMSE (Root Mean Squared Error)**
- * **R² (Coeficiente de Determinação)**
- * **MAPE (Erro Percentual Médio Absoluto)**

Essas métricas permitem avaliar tanto a precisão numérica quanto a aplicabilidade prática das previsões.

4.6 Rastreamento de Experimentos

Todos os experimentos foram registrados utilizando **MLflow**, incluindo:

- * parâmetros dos modelos
- * métricas de desempenho
- * versões dos modelos treinados

Isso garante **reprodutibilidade e rastreabilidade completa** do processo.

5. Resultados

Os modelos apresentaram os seguintes desempenhos:

Modelo	MAE (h)	RMSE (h)	R²	MAPE (%)
-----	-----	-----	----	-----
GradientBoosting	1808	2150	0.184	40.9
RandomForest	1839	2211	0.138	43.5
Lasso	1616	1877	0.378	48.9
Ridge	1879	2214	0.136	52.7
SVR	2810	3589	-1.27	70.0

6. Análise dos Resultados

- * O modelo **Gradient Boosting** apresentou o melhor desempenho em termos de RMSE.
- * O modelo **Lasso** apresentou melhor capacidade de generalização (maior R²).
- * O modelo **SVR** apresentou desempenho insatisfatório, indicando baixa adequação ao problema.

De forma geral, os resultados refletem a dificuldade do problema, especialmente devido ao **baixo volume de dados**.

Mesmo assim, os modelos apresentam desempenho suficiente para auxiliar em estimativas de planejamento de software.

7. Interpretabilidade do Modelo

Foi aplicada a técnica **SHAP (SHapley Additive Explanations)** para interpretar as previsões do modelo.

Essa análise permite:

- * identificar quais variáveis mais influenciam o esforço
- * entender o impacto de cada feature nas previsões
- * aumentar a transparência do modelo

8. Artefatos Gerados

Ao final desta etapa foram gerados:

- * modelos treinados e versionados
- * métricas de avaliação registradas
- * experimentos armazenados no MLflow
- * estrutura pronta para integração com API

9. Conclusão

A etapa de modelagem foi concluída com sucesso, resultando em um conjunto de modelos avaliados, comparados e rastreados.

O projeto agora possui um modelo capaz de estimar esforço de desenvolvimento com base em dados históricos, além de uma base sólida para evolução futura.

O próximo passo consiste na **integração do modelo em um serviço de previsão (API)**, permitindo seu uso em aplicações reais.

10. Informações de Entrega

* **Marco 2: Modelagem de Machine Learning**

Treinamento e avaliação de modelos de regressão, seleção do melhor modelo e geração de artefatos versionados.

* **Data de entrega:** 26/03/2026

* **Valor:** R\$ 460,00